СТИПЕНДИЯ РОССЕЛЬХОЗБАНКА 2026–2027 · «СВОЁ ФЕРМЕРСТВО» · ЗАДАЧА 5

Агрокаст

Прогноз урожайности на 5 дат сезона + оптимизация структуры посевов

–30 %
ошибки к прогнозу «как в прошлом году»

4 069
конфигураций моделей на единой проверке

+1 301 ₽/га
от малых изменений плана посевов

ПРОГНОЗ УТОЧНЯЕТСЯ ПО МЕРЕ СЕЗОНА

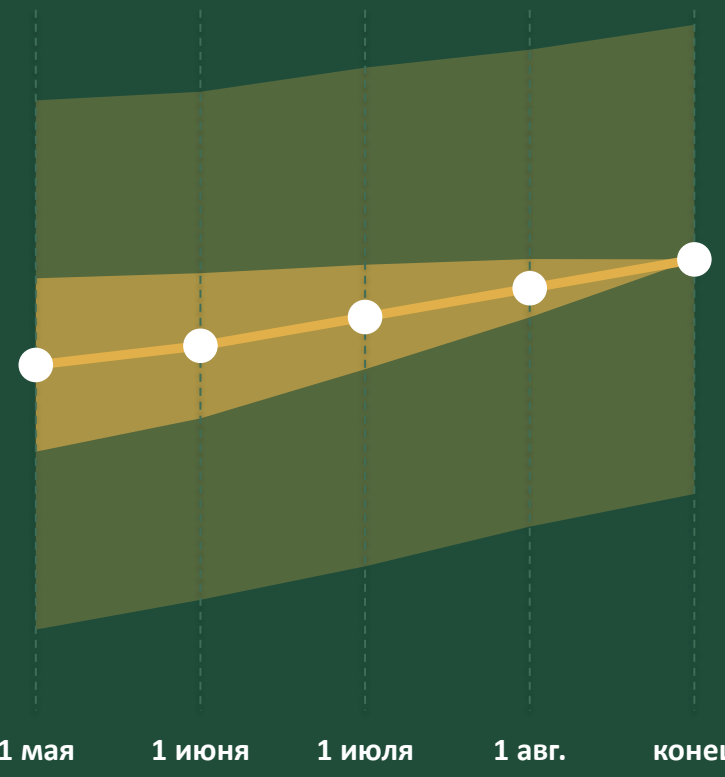


Схема. Широкая полоса — 80 % интервал по ошибкам прошлых лет, яркая — разброс погоды, которая ещё не наступила

Соболев Даниил · аспирант СПбПУ, специальность 5.2.2

Октябрь 2026 · решение участника конкурса, не продукт банка

ЗАДАЧА КЕЙСА

Прогноз — это решение: что сеять и сколько вложить

Кейс: урожайность в т/га и общий объём по культурам и польза для планирования затрат и доходов

₽ Фермеру

Что сеять: прогноз по культурам с 1 мая, а не после уборки

Сколько вложить: семена, удобрения, кредит под ожидаемый урожай

Что продавать вперёд: объём и диапазон «плохой — обычный — хороший год»

% Банку

Риск кредитов по регионам и культурам виден до уборки

График платежей под реальный, а не средний урожай

Ранний сигнал: проблемный сезон заметен уже летом

→ Наш ответ

Прогноз на 5 дат сезона с честным интервалом

Оптимизация: что изменить в плане, чтобы заработать больше при том же риске

Сайт с калькулятором хозяйства

Главная идея: не «модель предсказала N т/га», а рекомендация — изменить план немного и получить заметный эффект.

МАСШТАБ РАБОТЫ

Исследование на большом массиве данных, а не формула

17

источников открытых данных

ЕМИСС (74 показателя), ERA5, NASA POWER, SoilGrids, MODIS, GGCMI, FAOSTAT, USDA…

11,3 ГБ

сырых данных

55,7 тыс. файлов, 21 млн строк наблюдений; со всеми слоями — 12,0 ГБ

683

столбца в таблице признаков

81 тыс. строк «субъект × культура × год»: погода, окна культур, почвы, спутник

4 069

конфигураций моделей

на одной проверке 2012–2025; 10,2 тыс. попыток Optuna

89 × 7

субъектов РФ × культур

2000–2026, 450 точек пашни для погоды и почв

60

автоматических тестов

чистота данных, защита от утечек, проверка оптимизатора

КОНВЕЙЕР ДАННЫХ

Четыре слоя данных от сырья до сайта

ЕМИСС · ERA5 · NASA POWER · SoilGrids · MODIS · GGCMI · FAOSTAT · USDA PSD · Госреестр сортов · Росстат · и ещё 4

raw → interim → processed → clean → модель → сайт

raw	interim	processed	clean	модель	сайт
17	**90**	**40**	**17**	**683**	**4**
источников	**файлов**	**таблиц**	**таблиц**	**признаков**	**экрана**
55,7 тыс. файлов · 11,3 ГБ	**9,9 млн строк**	**8,4 млн строк**	**60 тестов**	**4 069 конфигураций**	**карта · регион · калькулятор · оптимизация**
как скачано, с докачкой и логами	сырой разбор без чистки: SDMX → таблицы	суточная погода, признаки, первые модели	правила чистки; строки не удаляются, а помечаются флагами	5 дат × 7 культур, проверка по времени	статический, работает без сервера

Честная проверка: модель видит только прошлое

1 · МОДЕЛЬ «ТРЕНД × ПОГОДА»

тренд по годам < t × **1 +** эффект погоды, спутника, почвы

2 · ПЯТЬ ДАТ ПРОГНОЗА: БУДУЩЕЕ ЗАМАСКИРОВАНО



3 · СКОЛЬЗЯЩАЯ ПРОВЕРКА 2012–2025

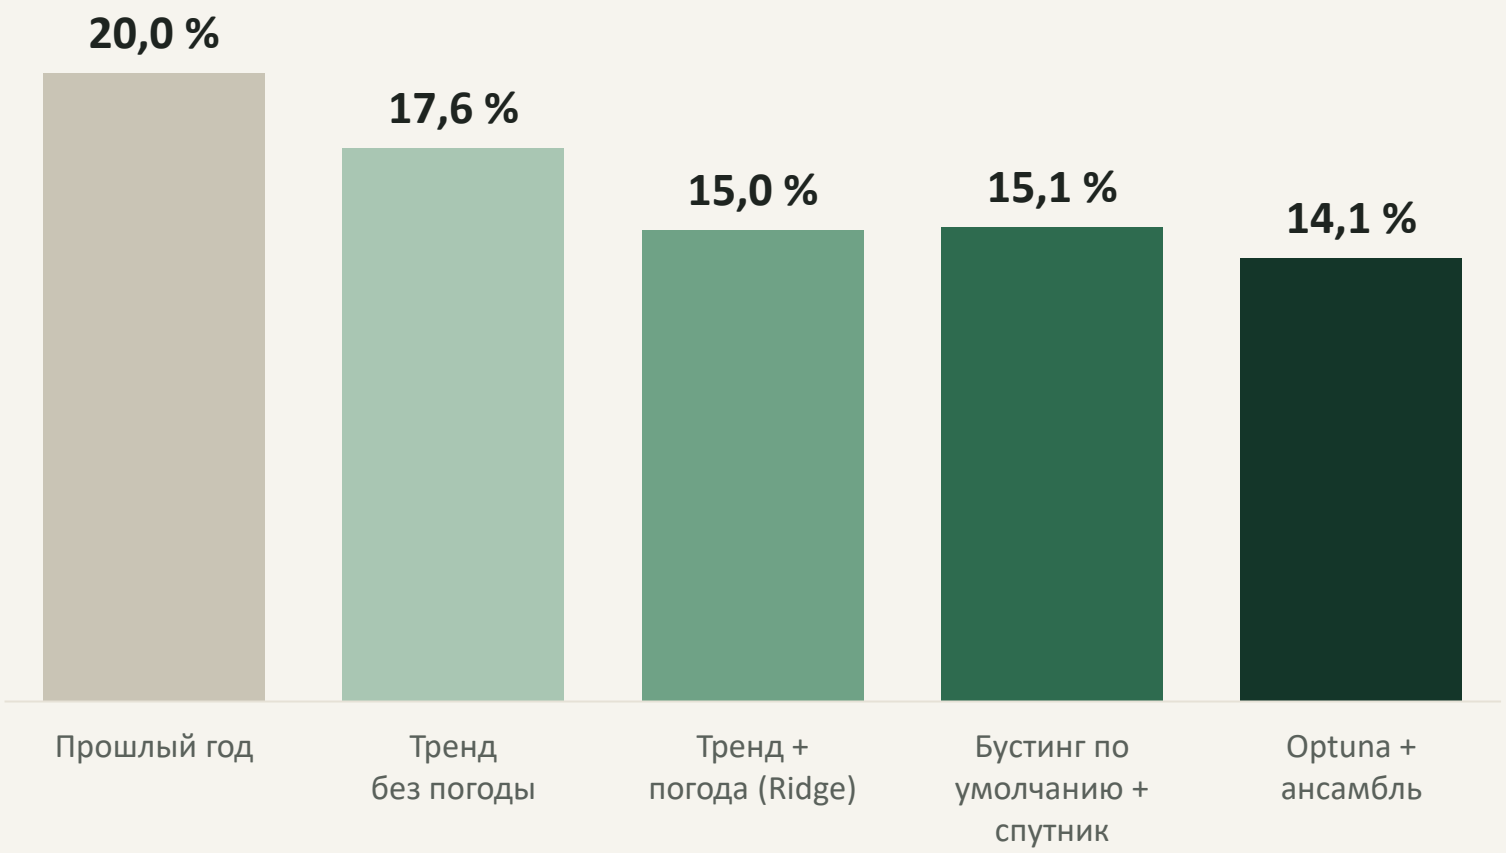


Тренды и нормы — только по годам < t · гиперпараметры подобраны по 2012–2018, годы 2019–2025 отложены · случайного разбиения нет

ГЛАВНЫЙ РЕЗУЛЬТАТ

Лесенка моделей: ошибка снижена на 30 %

Пять ступеней на одной проверке 2012–2025: средняя ошибка прогноза урожайности, % от факта (MAPE)



−30 %

ошибки (MAE и MAPE) к прогнозу «как в прошлом году», среднее по 7 культурам

Погода даёт основное: −25 % уже у линейной модели.

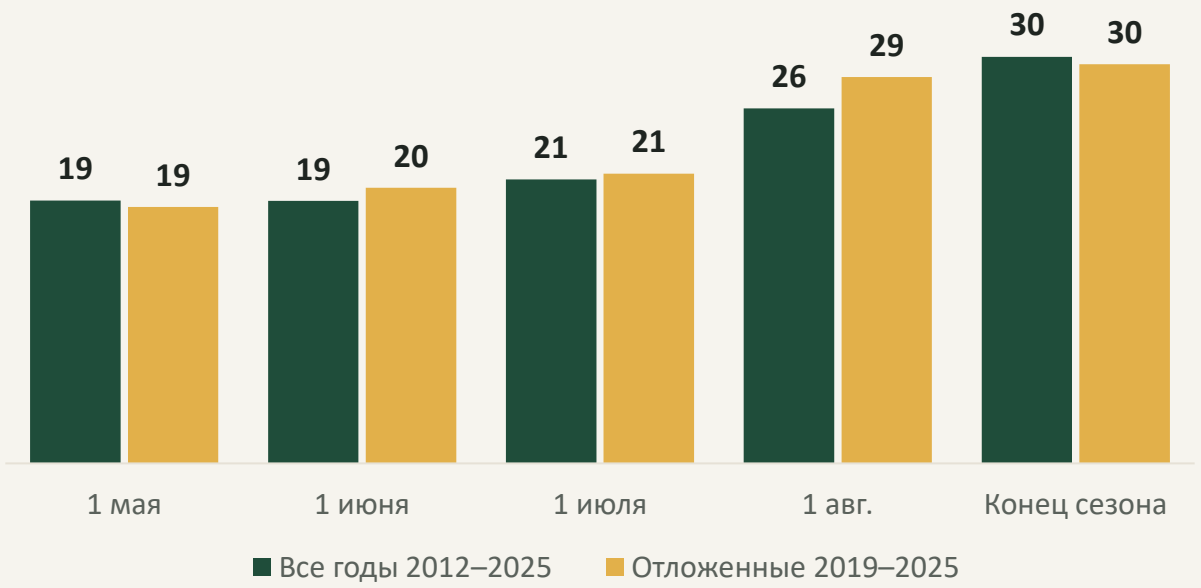
Бустинг «из коробки» со спутником не лучше (−25 %): выигрыш — от перебора и ансамбля.

Отложенные 2019–2025: −30 %, подгонки нет.

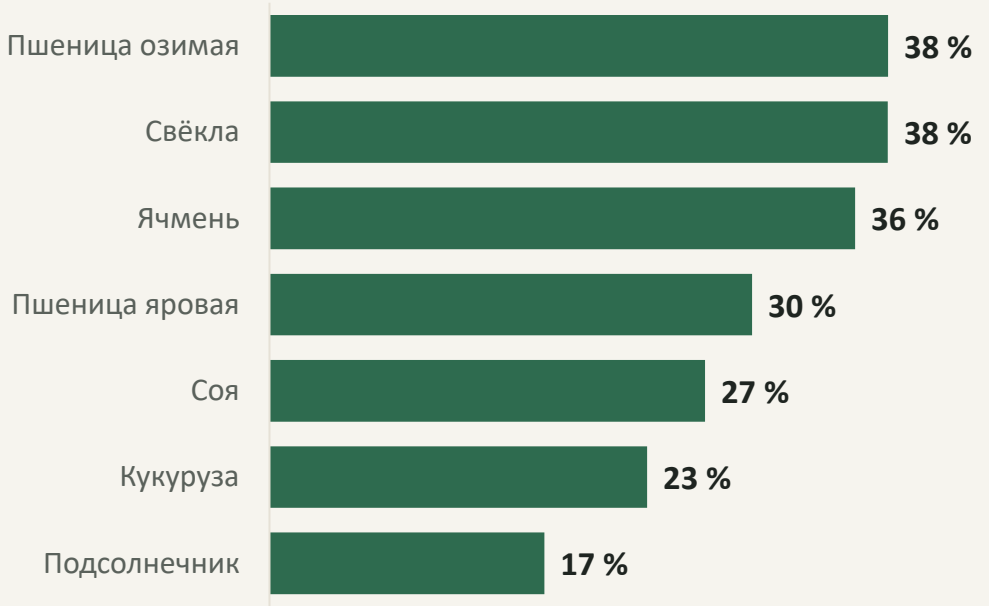
КАЧЕСТВО ПО ДАТАМ И КУЛЬТУРАМ

Ошибка падает уже с 1 мая: –19 %, к концу сезона –30 %

Снижение ошибки к «прошлому году», %



По культурам, конец сезона, %



83–93 % — покрытие 80 %-го интервала

доля фактов внутри интервала у всех 35 итоговых моделей

±24 % — полуширина интервала

к концу сезона; 1 мая — ±28 %: честный диапазон, не «точка»

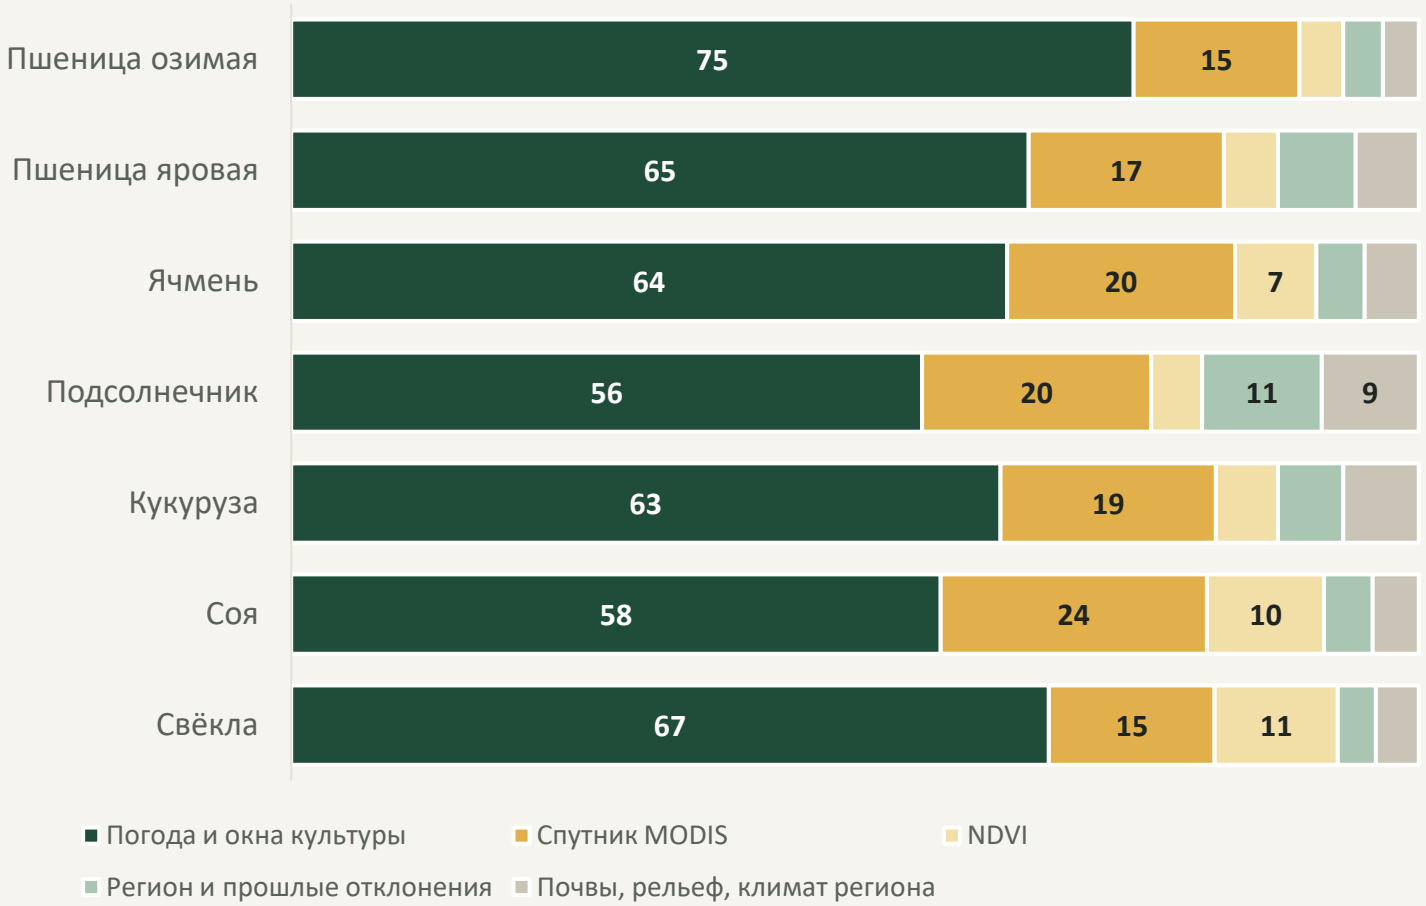
–14 % — озимая пшеница с 1 мая

к лучшему простому прогнозу; остальные культуры — с июля

ЧТО ДВИГАЕТ УРОЖАЙНОСТЬ

Погода даёт 56–75 % прогноза, спутник — 15–24 %

Доля блоков признаков в суммарном вкладе SHAP по культурам (LightGBM, TreeSHAP)



ЧТО ГОВОРЯТ ГЛАВНЫЕ ПРИЗНАКИ

Озимая пшеница: снег и минимальная температура в марте — выход из зимы; перегрев поверхности в мае–июне (LST)

Кукуруза: дефицит влажности воздуха в июле — засуха в цветение; влага почвы в августе

Сахарная свёкла: водный баланс окна вегетации и ГТК — самая влаголюбивая культура

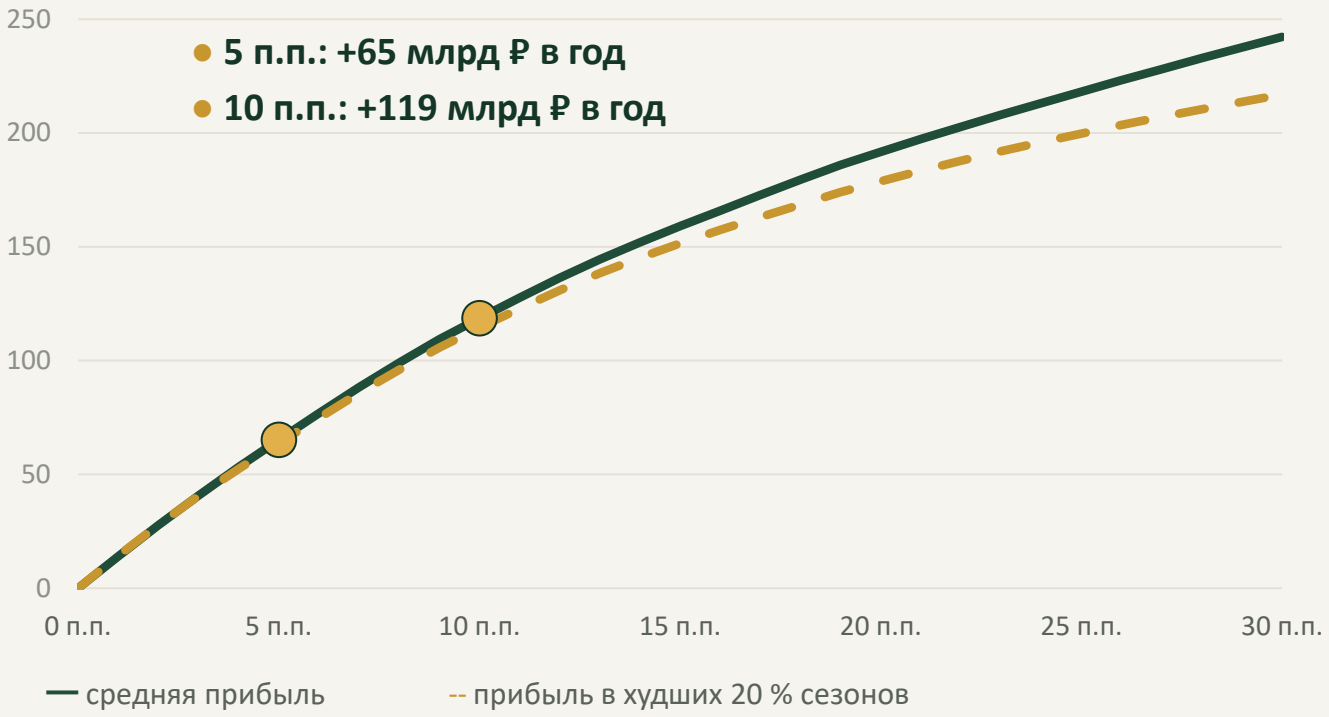
Ячмень: жаркий июнь и тёплые июльские ночи вредят

Спутник сильнее всего у **сои и подсолнечника**: у них погода региона объясняет меньше, а состояние посевов видно из космоса.

Изменить план немного — получить заметный эффект

Сценарная стохастическая оптимизация структуры посевов с CVaR и ограничением на отклонение от плана

Выигрыш по всем субъектам, млрд ₽ в год, при сдвиге структуры не более δ п.п.



Первые 10 п.п. дают 49 % эффекта, достижимого при 30 п.п.: дальше кривая выходит на плато

+1 301 ₽/га

ожидаемой прибыли при сдвиге ≤ 5 п.п. (+15 %)
медиана по субъектам +588 ₽/га, выигрыш у 97 %

+1 272 ₽/га

в худших 20 % сезонов (CVaR)
худший сезон лучше в 56 из 62 субъектов

Проверка на 2012–2025 (913 пар «субъект × год», только данные до года t, исторические сценарии):

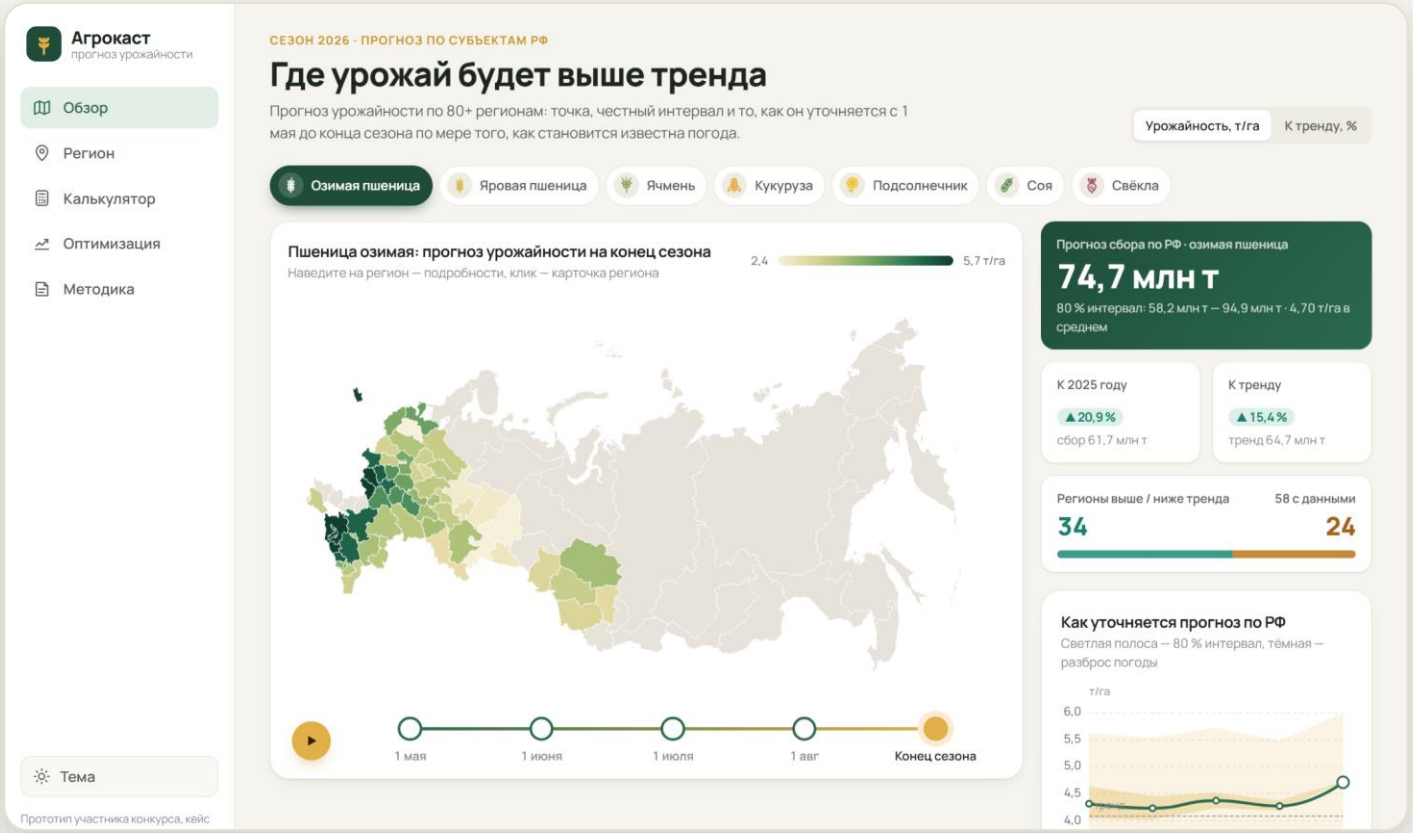
факт +961 ₽/га — 78 % обещанного; лучше текущего плана в 74 % случаев

62 субъекта, 50,1 млн га, 21 погодных сценарий. Затраты на гектар — допущения: эффект читать как верхнюю оценку

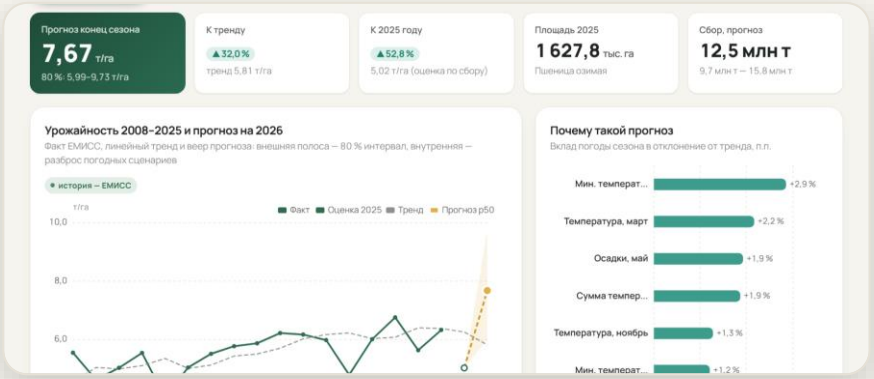
ПРОТОТИП

Агрокаст: прогноз и рекомендации в одном сайте

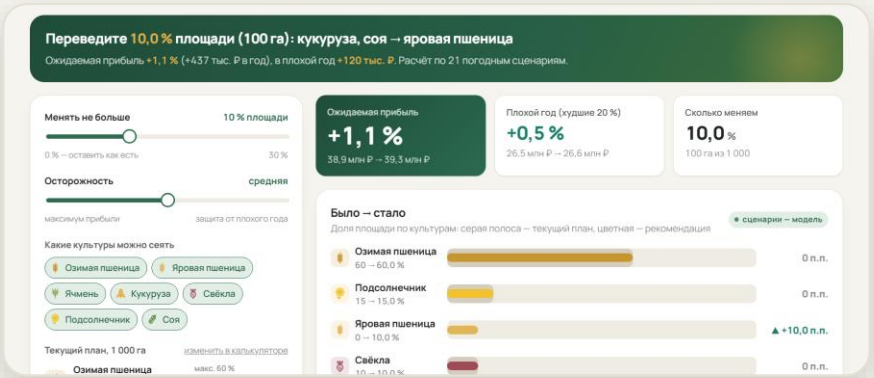
Карта · 7 культур · 5 дат



Карточка региона



Оптимизация



Код и сайт: https://parampaika.github.io/AgroCast/

Статический сайт без сервера: работает офлайн, готов к GitHub Pages

ЧЕСТНО И ДАЛЬШЕ

Ограничения и план развития

ОГРАНИЧЕНИЯ

Уровень — субъект РФ. Хозяйство учитывается поправками на почву, сорт и агротехнику.

Короткие ряды: 14 лет проверки, различия в 1–2 п. п. между конфигурациями — в пределах шума.

Интервалы широкие: ±24 % в конце сезона — это честная неопределённость.

2025 год: итогов Росстата ещё нет, урожайность восстановлена по сбору и посевной.

Затраты — допущения. Эффект оптимизации читать как верхнюю оценку.

ПЛАН РАЗВИТИЯ

1. **Районы и хозяйства**
   данные уровня района и хозяйства вместо региона
2. **Спутник в реальном времени**
   ежедневные NDVI/LAI с маской культур в течение сезона
3. **Цены и затраты**
   сценарии «цена × урожай», реальные нормативы затрат
4. **Удобрения и агротехника**
   кривые «доза → прибавка» и рекомендации по срокам
5. **Интеграция с данными банка**
   кредитные портфели, страхование, график платежей

ИТОГИ

Больше, чем модель: полноценное исследование

–30 %

ошибки к прогнозу «как в прошлом году» — на честной проверке по времени 2012–2025

17 → 683

источников данных → признаков: слои, тесты, воспроизводимая сборка

+1 301 ₽/га

от малых изменений плана посевов: оптимизация с CVaR, проверена на прошлом

Сайт, код, научный отчёт и тесты — в репозитории; всё пересобирается одной командой

Соболев Даниил

аспирант СПбПУ, специальность 5.2.2

e-mail: **sobolevdan2002@gmail.com**

Telegram: **https://t.me/Parampayka**

Репозиторий: **https://github.com/Parampaika/AgroCast**